

BEV-World-Model — Ergebnisse & Experimente (Stand 29.07.2026)

Handout zur Betreuerbesprechung · Masterarbeit Vincent Mann · UniBw München

1 · Setup in einem Absatz

Ein **4-Layer-Pre-LayerNorm-Transformer (~6M Parameter)** sagt das nächste BEV-Latent $x_{t+1} \in \mathbb{R}^{256 \times 128 \times 128}$ aus den 3 vorherigen Frames vorher (nuScenes, 2 Hz). Latents aus dem **eingefrorenen BEVFusion-Seg-Encoder**; Bewertung durch den eingefrorenen Seg-Decoder: $mIoU(\text{decode}(x_{t+1}), \text{decode}(x_t))$ auf dem vollen Val-Set (5743 Fenster). Pipeline: AvgPool-4-Downsampling → Zell-Tokens ($3 \times 32^2 = 3072$) + Positions-Encoding → Transformer → Output-Head → Upsampling → **Gated Skip**: $x_{t+1} = \alpha \cdot f(\text{Kontext}) + (1-\alpha) \cdot x_t$, $\alpha = \sigma(\text{Conv}1 \times 1)$ — das Modell lernt pro Zelle, ob es kopiert oder vorhersagt. Signifikanzschwelle (3-Seed-Studie): $|\Delta mIoU| > 0.014$.

2 · Loss-Engineering im Detail (Kernergebnis 1: „from six to two“)

Motivation: Regression auf mehrdeutige Ziele lernt den bedingten Mittelwert $E[x|\text{Kontext}]$ — zu glatt, zu varianzarm („std-Gap“: Vorhersage-Streuung ~9% unter real). Die 6 Terme greifen dieses Fehlerbild aus verschiedenen Richtungen an; jeder ist per λ einzeln schaltbar:

Term 1 — Multi-Scale-Rekonstruktion ($\lambda=1.0$, tragend)

$$L_{\text{MSR}} = \lambda \cdot [d(x_{t+1}, x_t)@128^2 + d(x_{t+1} \downarrow 2, x_t \downarrow 2)@64^2 + d(x_{t+1} \downarrow 4, x_t \downarrow 4)@32^2]$$

Punktweise Distanz d auf drei Auflösungen gleichzeitig ($\downarrow$ = AvgPool) — grobe Struktur und feine Details werden gemeinsam optimiert. Die Distanz d ist schaltbar; **SmoothL1** gewann: $d(e) = 0.5e^2/\beta$ für $|e| < \beta$, sonst $|e| - 0.5\beta$ ($\beta=1$). Nahe null wie MSE (präzise), bei großen Fehlern wie L1 (konstanter Gradient) — genau die seltenen großen Residuen sind die mehrdeutigen Stellen, und L1 zieht dort zum *Median* statt zum Mittelwert → weniger Mean-Seeking. Befund 16b.7: gleiche mIoU wie MSE, std-Gap signifikant besser (0.909→0.927). Gleiche Wahl wie DINO-Foresight.

Term 2 — Cosinus-Ähnlichkeit ($\lambda \rightarrow 0$ gestrichen)

$$L_{\text{Cos}} = 1 - \frac{\text{vec}(x_{t+1}) \cdot \text{vec}(x_t)}{(\|\text{vec}(x_{t+1})\| \cdot \|\text{vec}(x_t)\|)}$$

Matcht die *Richtung* der Feature-Vektoren unabhängig von der Amplitude; ursprünglich als Null-Kollaps-Schutz bei sparsamem Input eingeführt. Sweep: mIoU n.s., std-Ratio wird mit steigendem λ_{cos} signifikant und monoton schlechter → gestrichen.

Terme 3a/3b — Verteilungs-Matching: Kanal-Mittelwert & Kanal-Std (std tragend, $\lambda=1.0$)

$$L_{\text{3a}} = \text{MSE}(\mu_c(x_{t+1}), \mu_c(x_t)) \quad L_{\text{3b}} = \text{MSE}(\sigma_c(x_{t+1}), \sigma_c(x_t)) \quad \text{je Kanal } c$$

Idee (eigene Diagnose, Task 15): Der Mittelwert-Schätzer hat systematisch **zu wenig Varianz** ($\text{Var}(E[x|c]) < \text{Var}(x)$). Statt das indirekt zu hoffen, wird die Statistik der Ausgabe direkt an die des Ziels gebunden. $\lambda_{\text{std}}=1.0$ ist der Arbeitspunkt der ganzen Arbeit; λ_{mean} brachte nichts (Nullpunkt = Baseline). **Später zentral:** λ_{std} hält die Varianz auch im Rollout stabil (0.99–1.01) — die Eigenschaft, die generative Weltmodelle als Vorteil anführen, hier deterministisch erreicht.

Term 4 — Räumlicher Gradient ($\lambda=0$ geblieben)

$$L_{\text{4}} = \text{MSE}(\Delta x_{t+1}, \Delta x_t) + \text{MSE}(\Delta^2 x_{t+1}, \Delta^2 x_t) \quad (\text{finite Differenzen})$$


Anti-Blur-Idee aus der Bildrekonstruktion: Kanten/Hochfrequenz explizit matchen. Sweep: kein mIoU-Gewinn, std-Ratio bei höheren λ signifikant schlechter → aus.

Term 5 — SSIM ($\lambda \rightarrow 0$ gestrichen)

$$L_{\text{5}} = 1 - \text{SSIM}(x_{t+1}, x_t) = 1 - \frac{(2\mu_{x_{t+1}}\mu_{x_t} + c_1)(2\sigma_{x_{t+1}}\sigma_{x_t} + c_2)}{(\mu_{x_{t+1}}^2 + \mu_{x_t}^2 + c_1)(\sigma_{x_{t+1}}^2 + \sigma_{x_t}^2 + c_2)}$$

Strukturelle Ähnlichkeit über lokale Fenster-Statistiken (Bildqualitäts-Metrik). Überraschung im Sweep: mIoU sinkt **monoton** mit λ_{ssim} (0→0.687, 0.3→0.670, signifikant) → gestrichen.


Ergebnis: Nur Term 1 (SmoothL1) + Term 3b (λ_{std}) tragen: **mIoU 0.6946** = 6-Term-Baseline (0.6920, n.s.), std-Gap 9%→1.4%. **Einordnung LeWorldModel** (arXiv 2603.19312, JEPA): reduziert unabhängig von uns auf „Next-Embedding-Loss + Gauß-Regularisierer auf den Latents“ — strukturell dieselbe Zwei-Term-Philosophie (deren Regularisierer entspricht unserem std-Term). Wichtig: LeWM ist ein *deterministisches* JEPA, kein generatives Modell (s. §6).



3 · Systematische mIoU-Hebel — sechs Richtungen, alle flach/negativ (Kernergebnis 2)

Hebel	Implementierung (kurz)	Ergebnis vs. 0.6946
Ego-Conditioning (4 Variablen)	Ego-Delta [dx,dy,cosψ,sinψ] aus ego2global; injiziert per FiLM (γ, β) in FiLM/Tokens) 0.6816	Baseline
4 statt 3 Frames	Config-Schalter (PE skaliert mit)	-0.003 n.s.
EMA-Weight-Averaging	Shadow-Weights, decay 0.9999	-0.000 n.s.
Decoder-Task-Loss	BCE(decode(x̂), decode(x)) mit Gradienten DURCH den frozen Decoder (Training 0.16 Metriken) 0.6826	Baseline
Kapazität 8 Layer (9.2M)	Config-Schalter	-0.002 n.s.
Hartes Residual	x̂ = x_t + Head-Output (kein Gate)	-0.001 n.s. → Gate äquivalent, nicht nötig

Decke erklärt: per-Klasse fast gelöst bei groß/statisch (drivable 0.90), Restfehler in dünnen Strukturen (stop_line 0.56): aleatorische Unsicherheit (decode(t) vs decode(t+1) überlappt nur 0.53) + IoU-Randempfindlichkeit dünner Linien + 28k-Datengröße. Kein Messfehler (Same-Seed 2× auf 0.001 repliziert; monotone Dosis-Wirkungs-Effekte).



4 · Drei Modellklassen: Transformer vs. CVAE vs. Flow Matching

Transformer (unser deterministisches Backbone)

$$\text{Attention}(Q,K,V) = \text{softmax}(QK^T/\sqrt{d}) \cdot V, \quad Q=XW_Q, \quad K=XW_K, \quad V=XW_V$$

Jede der 3072 Zellen (Token) fragt per Attention alle anderen Zellen aller 3 Frames ab: „Wer ist relevant für meine Zukunft?“ — so fließt Bewegungsinformation von Frame zu Frame. Danach FFN, Residual-Verbindungen, Pre-LayerNorm; 4 solcher Blöcke. Der Transformer ist eine **deterministische Funktion** $f(\text{Kontext})$: ein Forward, eine Antwort. Mit Regressions-Loss trainiert lernt er $E[x|\text{Kontext}]$ — optimal für mIoU-artige Metriken, aber prinzipbedingt „gehedgt“ bei mehrdeutiger Zukunft.

CVAE — Conditional Variational Autoencoder (Task 18/B1)

$$\log p(x|c) \geq E_q[\log p(x|c,z)] - \beta \cdot \text{KL}(q(z|c,x) \parallel p(z|c)), \quad z = \mu + \sigma \cdot \epsilon \quad (\text{Reparametrisierung})$$

Erweitert das Backbone um eine kleine Zufallsvariable z (32-dim): Prior $p(z|c)$ sieht nur den Kontext, Posterior $q(z|c,x)$ sieht im Training zusätzlich das Ziel („welche Zukunft ist eingetreten?“); z wird per zero-init-FiLM in den Head injiziert. Der KL-Term zwingt Prior≈Posterior, damit man zur Inferenz ohne Ziel sampeln kann; Annealing + Free-Bits verhindern Posterior-Collapse. **Unser Befund:** technisch gesund (KL 0.2–0.4, Guard bestanden), aber **funktional deterministisch** — ein globales z kann räumlich lokalisierte Mehrdeutigkeit (dieses Auto biegt ab, jenes nicht) nicht ausdrücken; Diversität nur 0.06% der Maskenzellen. Gleiche Mechanik wie FIERYs Present/Future-Verteilungen und SVG-LP.

Flow Matching (Task 18/B2, VFMF/FlowWM-Linie)

$$r_\tau = (1-\tau) \cdot \epsilon + \tau \cdot r, \quad \text{Ziel } u = r - \epsilon, \quad L = \frac{1}{2} \|v_\theta(r_\tau, \tau, c) - u\|^2; \quad \text{Sampling: } dr/d\tau = v_\theta \\ (\text{Euler-ODE})$$

Kein Encoder, kein Posterior: ein eigenes Conv-Feld v_θ (~6.5M, Kapazitäts-Parität) lernt die **Geschwindigkeit**, mit der man Gauß-Rauschen entlang gerader Pfade in das Residuum $r = x - f(c)$ transportiert. Für jedes (τ, ϵ) -Paar ist das Ziel *eindeutig* — deshalb kein Mean-Collapse, obwohl die Loss eine MSE ist: das marginale Feld erzeugt beim ODE-Sampling die volle Verteilung. Stochastik ist **räumlich aufgelöst** (Feld über alle Zellen) statt global. Unser Befund: echte Diversität (37× CVAE), 1 Euler-Schritt genügt, post-hoc Skalierung $s=0.5$ kalibriert die Varianz und hebt Best-of-8 über den Mittelwert (Coverage).

	Transformer (det.)	CVAE	Flow Matching
lernt	Punktschätzer $E[x c]$	Verteilung via globalem z	Verteilung via Transport-Feld
Sampling	— (1 Forward, 1 Antwort)	z ziehen → 1 Forward	ODE-Schritte (hier: 1 genügt)
Stochastik	keine	global (32-dim)	räumlich aufgelöst
Hauptrisiko	Mean-Blur bei Mehrdeutigkeit	Posterior-Collapse / z ignoriert	Kalibrierung, Sampling-Kosten
unser Ergebnis	mIoU-optimal (0.6946); λ_{std} hält Variationsbreite	funktional deterministisch (Diversität 0.06%); λ_{std} hält Variationsbreite	Diversität 37×; kalibriert Best-of-8 > Mittelwert; Einzel-Sampling

Abgrenzung LeWorldModel: LeWM ist *keines* der generativen Verfahren, sondern ein deterministisches **JEPA** (Next-Embedding-Prediction + Gauß-Regularisierer, keine Samples). Es ist der aktuelle Standard der *Repräsentations-/Planungs-Schule* und entspricht strukturell unserem deterministischen Minimal-Setup; unser Flow Matching folgt dagegen der *generativen Schule* (VFMF 12/25, FlowWM 6/26 — dort aktueller Standard). Die Arbeit deckt damit beide Schulen ab.


5 · Rollout, Baselines & Generativ-Ergebnisse

Rollout k=1..4: mIoU 0.69→0.47, Modell schlägt Persistenz bei jedem k; Varianz bleibt kalibriert (λ_{std} -Erbe).

Ego-gewarppte Persistenz (Maske mit echter Ego-Bewegung transformiert): 0.629 vs naiv 0.533 → ehrlicher

Modell-Dynamikbeitrag +0.07. **Flow-Matching-Zerlegung:** Einzel-Sample-Malus −0.044 = −0.033 legitimer

Verteilungs-Preis (Perception-Distortion-Tradeoff, per Best-of-8 rückholbar) + −0.011 Kalibrierung (per Skalierung $s=0.5$ gelöst → Best-of-8 0.700 > Mittelwert 0.690).




6 · Det-Strang (Task 20): Transfer-Studie

Bausteine: (1) Latent-Extraktion im Docker (Saver-Hook, 34k Frames, 560 GB, Rolling-Sync). (2) **Normalisierung ×0.3641:** SmoothL1s MSE↔L1-Übergang liegt bei $\beta=1$ in absoluten Einheiten; Det-Latents sind 2.65× größer skaliert → ohne Normierung wäre die Loss effektiv L1-lastiger (β/σ 1.3 statt 3.6) und der Transfer-Vergleich unsauber. (3) **Injection-Messmaschine:** Docker-Forward per Env-Hook mit unseren Latents gefüttert, validierte nuScenes-Eval liefert mAP/NDS; Orakel-Gate reproduziert exakt 0.686/0.715 → Kette bewiesen, keine Cluster-Installationen.

Variante (Full-Val 6019)	mAP	NDS
Persistenz	0.170	0.391
World-Model minimal (smooth_l1+std)	0.326	0.466
World-Model 6-Term-Baseline	0.344	0.476
Orakel (Kopf-Decke)	0.686	0.715

Befund 1: World-Model verdoppelt die Persistenz-mAP — Dynamik-Lernen klar belegt, Methodik generalisiert.

Befund 2: „from six to two“ nur teilweise (minimal −0.017 unter 6-Term); Signifikanz klärt das laufende Seed-43-Replikat (Det-Rauschboden, Ergebnis ~29.07.).



7 · Metriken in einem Satz

Metrik	Bedeutung
mIoU (Seg)	Überlappung decodierter Karten mit dem decodierten echten Zielframe, Mittel über 6 Kartenklassen
std-Ratio	$\text{mean}(\text{Kanal-std Vorhersage})/\text{mean}(\text{Kanal-std real})$ — 1.0 = Varianz erhalten
mAP (Det)	Fläche unter Precision-Recall, Mittel über 10 Klassen $\times$ 4 Zentrumsabstands-Toleranzen (0.5–4 m)
NDS	$0.5 \cdot \text{mAP} + 0.5 \cdot \text{Treffer-Qualität}$ (Position/Größe/Orientierung/Geschwindigkeit/Attribut)
Best-of-K	bestes aus K Samples (SVG-Konvention) — deckt die Verteilung die echte Zukunft ab?

8 · Die fünf Kernbotschaften

1. Minimal-Loss genügt: $\text{smooth}_{l1} + \lambda_{\text{std}} = 6$ -Term-Baseline (Seg 0.6946; unabhängig durch LeWM/JEPA-Philosophie bestätigt). **2.** Die 0.69-Decke ist real und erklärt (6 Hebel getestet; aleatorisch + dünne Strukturen, nicht Kapazität). **3.** λ_{std} liefert Rollout-Varianz-Stabilität deterministisch — das Versprechen generativer Weltmodelle, fast gratis. **4.** Generativ lohnt für Multimodalität, nicht Genauigkeit: FM liefert echte Diversität + (kalibriert) Coverage über dem Mittelwert; CVAE-Sonde scheitert strukturell. **5.** Methodik generalisiert auf Detection: Persistenz-mAP verdoppelt; Injection-Protokoll mit exaktem Orakel-Gate als Mess-Muster.

9 · Status & offene Punkte

Abgeschlossen: 16b (Loss), 16c (Rollout), 16d/e/f (Hebel), 17 (Figuren + Komparator-Verifikation), 18 (CVAE, FM, Kalibrierung), 19 (Seg-Abschluss, Master-Tabelle 20 Varianten), 20 (Det-Kern). **Offen:** Seed-43-Rauschboden Det (läuft), optional Snapshot-Metrik-Kurve, Det-Umfang in der Thesis. Reproduzierbarkeit: ein Code-Pfad, alles config-schaltbar (Defaults bit-identisch), md5-synchron lokal $\leftrightarrow$ Cluster, alle Läufe mit Job-IDs in den Task-Berichten dokumentiert.