

BEV-World-Model — Projektkurzfassung

Masterarbeit V. Mann, UniBw München · Betreuer L. Pohl · Stand 31.07.2026

1 · Aufbau

Ein Transformer-World-Model sagt den nächsten BEV-Latent-Frame aus den drei vorherigen voraus. Die Latents ($256 \times 128 \times 128$) stammen aus dem **eingefrorenen** BEVFusion-Encoder (nuScenes, Kamera+LiDAR); ein ebenfalls eingefrorener Decoder übersetzt sie zur Messung in Segmentierungsmasken (6 Map-Klassen) bzw. — im Det-Strang — in 3D-Boxen (TransFusion-Kopf). Modell: 4-Layer-Pre-LN-Transformer, $d_{\text{model}}=256$, $3 \times 32^2=3072$ Tokens, gated Skip, $\sim 6,05\text{M}$ Parameter. Finale Loss ("from six to two"): SmoothL1-Rekonstruktion (multi-scale) + Channel-Std-Term ($\lambda=1$) — vier weitere geprüfte Terme (cos/mean/grad/ssim) sind auf Seg entbehrlich. Ein Code-Pfad für lokalen Server und DGX-Cluster, alles config-schaltbar, Defaults bit-identisch.

2 · Mess-Infrastruktur

Drei Ebenen: (a) **Proxy-mIoU** (300 Val-Samples, frozen Decoder) für Sweeps; (b) **Full-Val** (5743 Fenster) für Headlines; (c) **Injection-Protokoll**: vorhergesagte Latents werden per Hook in das originale BEVFusion eingespeist und mit dessen unveränderter Evaluationskette gegen **echte nuScenes-GT** gemessen (Seg: mIoU, Det: mAP/NDS). Orakel-Gates beweisen die Kette: injizierte reale Latents reproduzieren die Referenzwerte exakt (Seg 0,6295; Det 0,6858/0,7146). Signifikanz: $|\Delta \text{mIoU}| > 0,014$ (Seed-Studie); Det-Rauschboden 0,0044 mAP (Seed-Paar).

3 · Experimente (Tasks, chronologisch)

Task	Inhalt	Kernbefund
12–14	Latent-Extraktion, Baseline, Decode-Kette	Referenz mIoU 0,53 (Persistenz) etabliert
15–16b	Loss-Studie: 6 Terme, 5 Sweeps + recon-Schalter	Minimal-Konfig $\text{smooth_l1} + \text{std} = 0,6946 \approx 6\text{-Term (n.s.)}$; SmoothL1 schließt std-Gap
16c	Autoregressiver Rollout $k=1..4$	Modell schlägt Persistenz bei jedem k ; moderater Drift
16d	Ego-Conditioning (FiLM/Token/Gate)	Kein Gewinn; Injektionsmechanismus entscheidet
16e/16f	4 Frames, EMA, Task-Loss, 8 Layer, Residual	Alles flach/negativ $\rightarrow 0,69\text{-Decke}$ steht auf vier Beinen
17	Thesis-Figuren + Komparator-Verifikation	std-Gap $9,1 \rightarrow 1,4\%$; Filmstrip statisch/dynamisch
18	Generativ: CVAE $\rightarrow$ Flow Matching + Kalibrierung	CVAE quasi-deterministisch; FM echte Multimodalität ($37\times$), Coverage $+0,010$ (Best-of-8), det. Modell bleibt bester Betriebspunkt
19	Seg-Abschluss: Master-Tabelle, Decken-Analyse	$0,69 = \text{aleatorische Decke (per-Klasse-Zerlegung)}$
20	Det-Transfer (Injection, 2 Trainings, Seed-Paar)	Modell VERDOPPELT Persistenz-mAP ($0,17 \rightarrow 0,34$); 6-Term auf Det belegt besser ($+0,018 = 4\times$ Rauschboden)
21	Seg-GT-Verankerung (echte nuScenes-GT)	Rangfolge validiert; Selten-Klassen-Einbruch = überwiegend Decoder-Decke (Retention 89–98 %)
22	Selten-Klassen-/Dynamik-Hebel (läuft)	Gewichtete Loss $\times \{2,4,8\}$, Balanced/Dynamik-Sampler — 5-GPU-Sweep aktiv

4 · Kernergebnisse (Zahlen)


Metrik (Protokoll)	Persistenz	World-Model	Orakel/Decke
Seg mIoU vs. Pseudo-GT (Full-Val)	0,533 (naiv) / 0,629 (ego-warp)	0,6946 (Minimal)	$\sim 0,69 = \text{aleatorische Decke}$

Seg mIoU vs. echter GT (Injection)	0,465	0,590	0,629 (frozen Decoder)
Det mAP / NDS (Injection)	0,170 / 0,391	0,342 / 0,475 (6-Term, Seed-Mittel)	0,686 / 0,715
Rollout k=4 (Seg, mIoU)	0,35	~0,47	—

Kernaussagen: (1) Das World-Model lernt echte Dynamik — im Det-Korridor verdoppelt es die Persistenz. (2) Die Minimal-Loss ist eine Eigenschaft der Zielmetrik: auf Seg reichen 2 Terme, auf Det tragen die Struktur-Terme messbar. (3) Die 0,69-Decke ist sechsfach kreuzvalidiert und überwiegend aleatorisch/Decoder-bedingt; das Modell erreicht 93,7 % der Wahrnehmungs-Decke. (4) Generative Köpfe liefern Multimodalität und Coverage, aber keine Genauigkeit — der λ_{std} -Term gibt dem deterministischen Modell die Rollout-Stabilität, die generative Ansätze sonst versprechen.


5 · Schlüsselfiguren

Task 21 — Seg gegen ECHTE nuScenes-GT (Injection, frozen BEVFusion-Seg): Rangfolge bestaetigt; Selten-Klassen-Einbruch = ueberwiegend Decoder-Decke
Mittel (6 Klassen)



Task 21: Seg gegen echte GT — Korridor + per-Klasse-Zerlegung.

Task 20 — Det-Strang: World-Model verdoppelt die Persistenz; die 6-Term-Loss bleibt auf Det messbar besser
(Punkte = Einzel-Seeds 42/43, Balken = Mittel; Injection-Protokoll, frozen TransFusion-Kopf)



Task 20: Det-Korridor mit Seed-Punkten — Modell verdoppelt Persistenz.

6 · Offen / nächste Schritte

Task-22-Sweep (läuft): zellgewichtete SmoothL1 auf Selten-Klassen-Regionen, Balanced Sampler, Dynamik-Sampler; Sieger anschließend durch die GT-Injection-Eval inkl. neuer dynamik-stratifizierter Auswertung. Danach: Thesis-Schreiben — Figuren, Master-Tabelle, Referenzliste (inkl.

Frozen-vs-Co-trained-Einordnung 2026: JEPA-Linie trainiert Encoder ohne Decoder; Feature-Forecasting friert ein, mit Evidenz frozen > finetuned) liegen bereit.